

Documentacion del Analisis Exploratorio de Datos (EDA)

Que se hace en cada hoja de los Excel de analisis exploratorio,
que muestra cada grafico, y por que se usan PCA, biplot e ICC

Scripts documentados: `10_analisis_quimico.R`, `11_analisis_sensorial.R`, `11b_eda_cruzado_quimico_sensorial.R`

Carpeta: `Modelamiento/scripts/R/exploratorio/`

Generado 2026-07-07

Indice

1. Introduccion y alcance del EDA
2. Mapa general: que hace cada script y en que orden corre
3. Script 10_analisis_quimico.R
 - 3.1 Objetivo y datos de entrada
 - 3.2 Las 5 etapas del EDA aplicadas a la quimica
 - 3.3 Hojas del Excel analisis_quimico.xlsx
 - 3.4 Graficos PNG generados
 - 3.5 Por que PCA y biplot por grupo quimico
4. Script 11_analisis_sensorial.R
 - 4.1 Objetivo y datos de entrada
 - 4.2 Etapas 1 a 5 (EDA clasico aplicado a lo sensorial)
 - 4.3 Etapas 6 a 9 (ampliacion 2026-07-07)
 - 4.4 Hojas del Excel analisis_sensorial.xlsx
 - 4.5 Graficos PNG generados
 - 4.6 Por que radar charts, PCA sensorial e ICC
5. Script 11b_eda_cruzado_quimico_sensorial.R
 - 5.1 Objetivo y relacion con el resto del pipeline
 - 5.2 Hojas del Excel analisis_cruzado_quimico_sensorial.xlsx
 - 5.3 Graficos PNG generados
 - 5.4 Advertencias especificas de este analisis
6. Conceptos transversales en profundidad: PCA, biplot e ICC
7. Advertencias metodologicas generales del proyecto
8. Indice de archivos generados

1. Introduccion y alcance del EDA

Este documento explica, hoja por hoja y grafico por grafico, que hace cada uno de los tres scripts exploratorios del pipeline de la tesis: `10_analisis_quimico.R`, `11_analisis_sensorial.R` y `11b_eda_cruzado_quimico_sensorial.R`. El objetivo no es repetir el codigo, sino responder tres preguntas para cada salida: **que contiene**, **que pregunta responde** y, cuando aplica, **por que se eligio esa tecnica estadistica** (PCA, biplot, ICC, correlacion, radar chart) en vez de otra.

Los tres scripts siguen el mismo esquema clasico de Analisis Exploratorio de Datos (EDA) en 5 etapas —descriptivo, tipos de variable, datos ausentes, valores atipicos, correlacion— adaptado en cada caso a la naturaleza de los datos (quimicos, sensoriales, o el cruce entre ambos). El script sensorial ademas incorpora 4 etapas adicionales especificas (perfil por categoria de catador, radar charts, PCA sensorial y concordancia entre evaluadores).

Es importante remarcar desde ya lo que estos tres scripts **no** son: no ajustan modelos supervisados, no seleccionan variables para prediccion y no reemplazan el diagnostico formal de colinealidad. Esa parte del pipeline vive en `scripts/R/modelamiento/` (13 en adelante) y en `scripts/R/analisis_finales/` (18-19). El EDA es la etapa previa: entender la forma, calidad y estructura de los datos antes de modelar.

2. Mapa general: que hace cada script y en que orden corre

Script	Entrada	Salida Excel	Que responde
10_analisis_quimico.R	quimica_unidades.xlsx	analisis_quimico.xlsx	Como se comportan las variables quimicas (GC-FID, GC-MS, JU, fenoles totales) por separado: distribucion, completitud, outliers, correlacion interna y agrupamiento de muestras por tecnica.
11_analisis_sensorial.R	sensorial_targets.xlsx	analisis_sensorial.xlsx	Como se comportan los 34 targets sensoriales: distribucion, completitud, outliers, correlacion entre descriptores, perfil por muestra y por categoria de catador, y que tan de acuerdo estan los evaluadores entre si.
11b_edc_cruzado_quimico_sensorial.R	matriz_pura.xlsx (A_pura)	analisis_cruzado_quimico_sensorial.xlsx	Vista previa exploratoria de la relacion predictor quimico ↔ target sensorial en el escenario principal, antes del diagnostico formal de colinealidad.

Los tres corren **despues** de que las matrices de procesamiento (scripts 00 a 09 en `scripts/R/procesamiento/`) ya existen, porque leen sus archivos de salida. El orden interno es 10 → 11 → 11b, porque el cruce quimico-sensorial necesita `matriz_pura.xlsx`, que a su vez depende de que la quimica y lo sensorial ya se hayan extraido.

3. Script 10_analisis_quimico.R

3.1 Objetivo y datos de entrada

Lee `data/procesamiento/quimica_unidades.xlsx` (hoja `01_quimica_wide`): una fila por *unidad analitica* (una medicion quimica real, no una muestra fisica —una misma muestra puede tener varias unidades analiticas si se midio con mas de una tecnica). Cada unidad analitica se clasifica en un `grupo_quimico`: **GC-FID**, **GC-MS**, **JU** (fermentacion) o **Fenoles totales** (Folin-Ciocalteu). Esta clasificacion es la base de casi todo el script, porque estas cuatro tecnicas **no comparten variables ni siempre las mismas muestras**: mezclar sus datos en un solo analisis produciria matrices llenas de vacios estructurales y comparaciones sin sentido (unidades y escalas distintas). Por eso casi todas las etapas del script se repiten *por grupo quimico* en vez de hacerse una sola vez de forma global.

3.2 Las 5 etapas del EDA aplicadas a la quimica

Eta	Que hace	Por que asi
1. Descriptivo	Resumen global y por bloque analitico; histogramas de cada variable, uno por grupo quimico.	Antes de cualquier calculo hay que ver cuantas unidades hay, con que cobertura, y como se distribuye cada variable (asimetria, escala, valores extremos a simple vista).
2. Tipos de variable	Verifica que todas las columnas <code>x_ / ctrl_ / n_</code> sean numericas y las etiqueta por grupo (GC-FID, GC-MS, JU, Fenoles totales).	La extraccion original (script 02) ya convierte a numerico; aqui se deja registro explicito de esa verificacion, requisito minimo del esquema EDA clasico.
3. Datos ausentes	Calcula el % de completitud por variable y por bloque, y lo visualiza como mapa de calor (variable x bloque).	En este proyecto los vacios no son errores de captura : cada tecnica analitica mide un subconjunto fijo de variables, asi que un vacio significa "esta tecnica no mide esto", no "dato perdido". El mapa de calor deja esto visualmente evidente en vez de una tabla de NAs que se presta a mala interpretacion.
4. Valores atipicos	Regla IQR ($Q1-1.5 \times IQR$, $Q3+1.5 \times IQR$) por variable, con minimo 4 observaciones para calcularla. Se documentan en una hoja y se marcan en los boxplots (color rojo), pero nunca se eliminan ni se imputan .	Son mediciones quimicas reales de un numero pequeno de muestras (small data); eliminar un outlier sin evidencia analitica de error seria fabricar/alterar datos. La regla queda solo como documentacion para discusion posterior.
5. Correlacion y PCA	Correlaciones de Pearson ≥ 0.8 dentro de cada grupo quimico (heatmap), y un PCA + biplot tambien por grupo.	Ver seccion 3.5 para la justificacion detallada de PCA/biplot.

3.3 Hojas del Excel analisis_quimico.xlsx

Hoja	Contenido
------	-----------

00_resumen	Indicadores globales: unidad de analisis, total de unidades analiticas, cuantas tienen cata confirmada, numero de bloques y grupos quimicos, numero de variables quimicas detectadas.
01_resumen_bloques	Por cada bloque analitico (ej. <code>gcfid_constanza_enero</code>): numero de unidades analiticas, muestras base distintas, con/sin cata confirmada, y promedio de variables disponibles por unidad.
02_descriptivos	Estadistica descriptiva completa (n, media, desviacion estandar, minimo, mediana, maximo, % completitud) de cada variable quimica , agrupada por tecnica analitica.
03_tipos_variables	Cada variable con su clase en R (numeric/character/etc.) y el grupo al que pertenece (GC-FID, GC-MS, JU, Fenoles totales).
04_completitud	Version tabular del mapa de calor de la etapa 3: % de datos disponibles por variable.
05_outliers_detectados	Lista fila por fila de las mediciones marcadas como atipicas por la regla IQR, con el valor observado y los limites usados.
06_resumen_outliers	Conteo de cuantos outliers tiene cada variable, ordenado de mayor a menor.
07_correlaciones_altas	Pares de variables quimicas con $ r \geq 0.8$, calculadas dentro de cada grupo quimico (nunca entre grupos distintos).
08_pca_resumen	Por cada grupo quimico: si el PCA se pudo calcular, cuantas filas/variables uso, y que % de varianza explican PC1, PC2 y ambos juntos.
09_pca_scores	Coordenadas (PC1, PC2, PC3) de cada unidad analitica en el espacio de componentes principales —la base para ubicar cada muestra en el biplot.
10_pca_cargas	<i>Loadings</i> : cuanto pesa cada variable original en PC1/PC2/PC3 —la base para las flechas del biplot.
11_diccionario_variables	Tabla de referencia rapida: variable → grupo → clase R.
12_notas	Resumen en texto de las 5 etapas y de la decision de separar todo por grupo quimico.

3.4 Graficos PNG generados

Archivo	Que muestra
01_histogramas_<grupo>.png	Un panel de histogramas (uno por variable) para cada grupo quimico —forma de la distribucion, asimetria, rango.
02_mapa_completitud.png	Heatmap variable × bloque analitico: celdas claras = poca cobertura, celdas azules = cobertura completa.
03_boxplots_<grupo>.png	Boxplots por variable dentro de cada grupo, con los outliers IQR marcados en rojo.
04_correlacion_<grupo>.png	Heatmap de correlacion de Pearson entre todas las variables de ese grupo, con el valor de r impreso en cada celda.
05_biplot_pca_<grupo>.png	Biplot PCA (PC1 vs PC2): puntos = unidades analiticas, flechas rojas = variables originales.

3.5 Por que PCA y biplot por grupo quimico

El problema que resuelve: cada grupo quimico puede tener entre 5 y 13 variables medidas sobre un numero reducido de unidades analiticas. Mirar tabla por tabla o correlacion por correlacion no deja ver el patron completo: *¿que muestras se parecen entre si considerando todas las variables a la vez, y por que variables se separan del resto?* Esa es exactamente la pregunta que responde un biplot PCA.

Por que por grupo y no un PCA global: GC-FID, GC-MS, JU y Fenoles totales no comparten variables ni siempre las mismas muestras (bloques analiticos no solapados, ver seccion 7). Un PCA global exigiria casos completos en las 32 variables x_* a la vez, lo que dejaria fuera a casi todas las unidades analiticas y mezclaria escalas no comparables (ppm de GC-FID contra % de GC-MS). Por eso, igual que en el diagnostico de colinealidad del modelamiento (script 13b), el

PCA se calcula **separado por tecnica analitica**.

Por que se centra y escala (`scale.=TRUE`): las variables quimicas tienen unidades y magnitudes muy distintas (ppm vs porcentajes). Sin estandarizar, las variables con valores mas grandes dominarian artificialmente los componentes principales solo por su escala, no por su varianza real.

4. Script 11_analisis_sensorial.R

4.1 Objetivo y datos de entrada

Lee `data/procesamiento/sensorial_targets.xlsx`, principalmente las hojas `01_sensorial_agregado_wide` (promedio por muestra) y `02_sensorial_individual_wide` (una fila por evaluacion individual de un catador). Cubre 5 bloques sensoriales (`cata_alexandra_260603`, `sensorial_cepas_ju`, `cata_septiembre_2024`, `cata_social_enero_2025`, `panel_noviembre`) y 34 targets `y_*`. Igual que en la quimica, cada formulario/bloque mide un subconjunto distinto de descriptores, por lo que varias etapas se repiten por bloque.

4.2 Etapas 1 a 5 (EDA clasico aplicado a lo sensorial)

Eta ­ pa	Que hace	Por que asi
1. Descriptivo	Resumen global, por bloque y por muestra; histogramas de los 34 targets.	Igual logica que en quimica: ver volumen, cobertura y forma de cada descriptor antes de comparar nada.
2. Tipos de variable	Verifica que los 34 targets <code>y_*</code> sean numericos y marca cuales son "targets principales" (<code>y_frutal_comun</code> , <code>y_fenolico_comun</code> , <code>y_ahumado_comun</code> , <code>y_medicinal_comun</code>).	Estos 4 targets combinados son los que se usan en el modelamiento (ver <code>[[tesis_whisky_resultados_modelamiento]]</code>); marcarlos aqui evita tener que redefinir la lista en cada seccion posterior.
3. Datos ausentes	% de completitud por target y bloque, mapa de calor.	Cada formulario de cata pregunta un subconjunto distinto de atributos (por ejemplo, "Sensacion en boca" solo existe en algunos formularios) —los vacios son estructurales, no errores.
4. Valores atipicos	Regla IQR por target; se documentan y marcan en boxplots (por bloque y por muestra dentro de cada bloque), nunca se eliminan .	Son evaluaciones reales de catadores. Un puntaje "raro" puede ser justamente el dato mas interesante (un catador que percibe algo distinto), no un error a corregir.
5. Correlacion entre targets	Correlacion de Pearson entre los 34 targets, a nivel de evaluacion individual, con heatmap completo.	Permite ver que descriptores tienden a moverse juntos (ej. "aroma medicinal" y "medicinal comun" con $r=0.91$) antes de decidir que targets usar como principales en el modelamiento.

4.3 Etapas 6 a 9 (ampliacion 2026-07-07)

Estas cuatro etapas se agregaron para aprovechar dos cosas que existian en los datos originales pero no se usaban en el pipeline: la **categoria de catador** (solo registrada en la cata social de enero 2025) y la posibilidad de comparar el perfil sensorial completo de varias muestras a la vez (los graficos radar que antes se armaban a mano en Excel).

Eta ­ pa	Que hace	Por que asi
6. Perfil por categoria de catador	Media y desviacion estandar de cada target por muestra y por categoria	Antes esta columna se leia del archivo original pero no llegaba a ningun script. Permite responder si el nivel de experiencia del catador cambia sistematicamente el puntaje o la dispersion.

	(Experto/Sommelier, Aficionado al whisky, Consumidor General de Destilados), mas un boxplot comparativo en los 4 targets principales.	
7. Radar charts	Grafico radar (ggplot2 + coord_polar) por bloque, comparando el perfil promedio de todas sus muestras en tres grupos de descriptores (Aroma, Sabor, Regusto-Final); y un segundo set por muestra de la cata social, comparando las 3 categorias de catador mas una linea "Promedio".	Ver seccion 4.6.
8. PCA sensorial por bloque	PCA (centrado/escalado) de los targets sensoriales, calculado por separado en cada bloque, con su biplot.	Mismo principio que en la quimica: cada formulario mide un subconjunto de descriptores distinto, asi que el PCA no puede ser global.
9. Concordancia entre evaluadores (ICC)	ICC(1) de una via por bloque y target, y por categoria de catador en los targets principales.	Ver seccion 4.6.

4.4 Hojas del Excel analisis_sensorial.xlsx

Hoja	Contenido
00_resumen	Indicadores globales: unidad individual, muestras y evaluaciones totales, con/sin quimica confirmada, bloques, targets detectados, muestras agregadas.
01_resumen_bloques	Por bloque sensorial: muestras, evaluaciones individuales, evaluadores distintos, con/sin quimica, tipo de panel (individual/pequeno/amplio).
02_resumen_muestras	Por muestra: numero de evaluaciones y de evaluadores, tipo de panel.
03_descriptivos_targets	Estadistica descriptiva (n, media, sd, min, mediana, max, % completitud) de cada uno de los 34 targets, a nivel de evaluacion individual.
04_descriptivos_bloques	Lo mismo, pero desglosado por bloque sensorial x target.
05_tipos_targets	Clase R de cada target y si es uno de los 4 targets principales.
06_completitud_muestras	Por muestra: cuantos targets tiene disponibles en promedio, minimo y maximo entre sus evaluadores.
07_outliers_detectados	Evaluaciones individuales marcadas como atipicas (regla IQR) por target, con catador y muestra identificados.
08_resumen_outliers	Conteo de outliers por target.
09_variabilidad_principales	Para los 4 targets principales: media, sd, rango por muestra, clasificados como variabilidad baja/media/alta.
10_correlacion_targets	Todos los pares de targets con su correlacion de Pearson, ordenados de mayor a menor r .

11_perfil_muestras	Promedio agregado de los 34 targets por muestra (formato ancho).
12_perfil_muestras_largo	Lo mismo en formato largo (una fila por muestra x target) —es el insumo de los radar charts por muestra.
13_targets_modelamiento	Resumen de <code>y_frutal_comun</code> y <code>y_fenolico_comun</code> por bloque (los dos targets usados en el modelamiento supervisado).
14_targets_muestra	Esos mismos dos targets, valor promedio por muestra.
15_sensorial_sin_quimica	Evaluaciones de muestras que no tienen quimica confirmada asociada (base del escenario <code>G_sensorial_sola</code>).
16_perfil_categoria_catador (nuevo)	Media, sd y n de evaluaciones por muestra x categoria de catador x target (solo cata social de enero 2025).
17_consistencia_catador (nuevo)	Por categoria de catador: sd promedio y media promedio a traves de todos los targets —responde que tan consistente es cada tipo de catador.
18_pca_sensorial_resumen (nuevo)	Por bloque sensorial: si el PCA se calculo, cuantas muestras/targets uso, y % de varianza explicada por PC1/PC2.
19_pca_sensorial_scores (nuevo)	Coordenadas PC1-PC3 de cada muestra dentro de su bloque.
20_pca_sensorial_cargas (nuevo)	Loadings de cada target en PC1-PC3 —base de las flechas del biplot sensorial.
21_concordancia_muestras (nuevo)	ICC(1) por bloque x target: que tan de acuerdo estan los evaluadores al diferenciar las muestras en ese descriptor.
22_concordancia_catador (nuevo)	ICC(1) por categoria de catador x target principal: si expertos, aficionados o consumidores generales concuerdan mas o menos entre si.
23_notas	Resumen en texto de las 9 etapas.

4.5 Graficos PNG generados

Archivo	Que muestra
01_histogramas_targets.png	Panel de histogramas de los 34 targets (todas las evaluaciones individuales).
02_mapa_completitud.png	Heatmap target × bloque: que descriptores mide cada formulario.
03_boxplots_targets_por_bloque.png	Boxplots de los 4 targets principales, comparando los 5 bloques sensoriales.
04_boxplots_muestra_<bloque>.png	Boxplots de los targets principales por muestra, uno por bloque.
05_correlacion_targets.png	Heatmap de correlacion completo entre los 34 targets.
06_boxplot_categoria_catador.png (nuevo)	Boxplot de los 4 targets principales segun categoria de catador (cata social).
07_radar_muestras_<bloque>_<grupo>.png (nuevo)	Radar comparando el perfil promedio de todas las muestras de un bloque, para Aroma / Sabor / Regusto-Final.
08_radar_categoria_<muestra>_<grupo>.png (nuevo)	Radar de una muestra de la cata social comparando Experto/Sommelier, Aficionado, Consumidor General y el Promedio.
09_biplot_pca_sensorial_<bloque>.png (nuevo)	Biplot PCA de los targets sensoriales de ese bloque, muestras etiquetadas por su identificador.

4.6 Por que radar charts, PCA sensorial e ICC en este script

Radar chart (grafico de tela de arana): es el grafico natural cuando se quiere comparar *varios objetos* (aqui, muestras o categorias de catador) sobre *varios atributos con la misma escala* (aqui, puntajes 0-5) a la vez, en un solo golpe de vista. Cada eje es un descriptor (Ahumado, Medicinal, Frutal, etc.), cada linea es una muestra o categoria, y la forma del poligono resultante es la "silueta sensorial" de ese objeto. Se eligio reproducirlo en R (con `ggplot2` + `coord_polar`, sin depender del paquete `fmsb`) en vez de mantenerlo como un grafico manual en Excel, para que se regenere automaticamente cada vez que cambien los datos y quede versionado junto al resto del pipeline.

PCA sensorial por bloque: misma logica que en la quimica (seccion 3.5): con hasta 22 descriptores midiendo solo 3 a 6 muestras por bloque, el PCA permite ver de un vistazo que muestras tienen un perfil sensorial parecido y que descriptores explican esa cercania, sin tener que cruzar 22 correlaciones una por una. Tambien se calcula por bloque y no de forma global por la misma razon: cada formulario mide un subconjunto distinto de descriptores.

ICC (concordancia entre evaluadores): la matriz de modelamiento usa el *promedio* de varios catadores por muestra. Ese promedio solo es un buen resumen si los catadores tienden a estar de acuerdo entre si sobre cual muestra puntua mas alto o mas bajo en un descriptor. El ICC(1) mide exactamente eso, separando la varianza total en "diferencia real entre muestras" y "ruido entre evaluadores" (ver formula y umbrales en la seccion 6). Se calculo tambien por categoria de catador para responder una pregunta concreta que surgio al revisar los datos: *¿los expertos concuerdan mas entre si que los consumidores generales?*

5. Script 11b_eda_cruzado_quimico_sensorial.R

5.1 Objetivo y relacion con el resto del pipeline

Los scripts 10 y 11 analizan la quimica y lo sensorial **por separado**. Este script da la primera mirada exploratoria a la relacion entre ambos lados, usando `data/procesamiento/matriz_pura.xlsx` (escenario **A_pura**, el escenario principal real: quimica real cruzada con cata real agregada por muestra, 52 filas $\times$ 32 predictores $\times$ 34 targets y_*).

Este script es deliberadamente simple: calcula correlaciones pareadas, no VIF ni modelos. El diagnostico formal de colinealidad (que si usa VIF por bloque y por modelo reducido, dado que el VIF global no es aplicable por la baja superposicion entre tecnicas analiticas) sigue viviendo en `scripts/R/modelamiento/13b_colinealidad_modelamiento.R`. Este script 11b es solo un vistazo previo, rapido de leer, antes de llegar a esa etapa.

5.2 Hojas del Excel `analisis_cruzado_quimico_sensorial.xlsx`

Hoja	Contenido
00_resumen	Escenario usado (A_pura), numero de filas, de predictores, de targets, cuales son los targets principales, y advertencia sobre el VIF global.
01_correlacion_cruzada	La matriz completa: cada combinacion predictor $\times$ target con su correlacion de Pearson y el numero de pares validos usado para calcularla (<code>n_pares</code>).
02_correlacion_principales	El mismo cruce pero filtrado a los 4 targets principales, con el predictor clasificado por grupo quimico (GC-FID/GC-MS/JU/Fenoles totales) —es la base del heatmap principal.
03_pares_correlacion_alta	Todos los pares predictor-target con $ r \geq 0.5$, ordenados de mayor a menor, para revisar rapido cuales sobresalen.
04_notas	Notas metodologicas: como se calculo cada correlacion, por que se separa por grupo quimico, y la advertencia de no interpretar esto como causalidad ni como importancia de variable.

5.3 Graficos PNG generados

Archivo	Que muestra
01_heatmap_predictores_targets_principales.png	Heatmap de todos los 32 predictores (filas) contra los 4 targets principales (columnas), con el valor de r impreso.
02_heatmap_<grupo>.png	El mismo cruce pero separado por grupo quimico (GC-FID, GC-MS, JU, Fenoles totales), mas facil de leer que el heatmap completo.

5.4 Advertencias especificas de este analisis

n pequeno y variable por par: como cada tecnica analitica solo cubre un subconjunto de las 52 filas de A_pura, muchas correlaciones se calculan con apenas 5 a 9 pares de datos (columna `n_pares` en la hoja 01). Correlaciones altas con n tan chico son faciles de que ocurran por azar; se exige un minimo de 5 pares para reportar el valor, pero incluso asi deben leerse como pistas exploratorias, no como evidencia estadistica fuerte.

No es importancia de variable ni causalidad: una correlacion alta entre un predictor JU (fermentativo) y un target fenolico no implica que ese compuesto cause el atributo sensorial —las variables JU son senales fermentativas indirectas (ver seccion 7). La lectura correcta de este script es "que variables merece la pena mirar primero en el diagnostico formal", no una conclusion en si misma.

Como validacion cruzada: los predictores que este script marca con mayor correlacion hacia lo fenolico/ahumado (`gcfid_guaiacol_ppm`, `gcfid_4_ethyl_guaiacol_ppm`, `gcfid_o_cresol_ppm`, `gcfid_p_cresol_ppm`) coinciden con los que la interpretabilidad del modelamiento (script 17/18) ya habia identificado como quimicamente coherentes —una senal de consistencia entre el EDA temprano y el resultado final del modelamiento.

6. Conceptos transversales en profundidad: PCA, biplot e ICC

PCA — Analisis de Componentes Principales

Que es: una tecnica de reduccion de dimensionalidad. Toma un conjunto de variables numericas correlacionadas entre si y las transforma en un nuevo conjunto de variables no correlacionadas (los *componentes principales*, PC1, PC2, PC3...), ordenadas de forma que PC1 capture la mayor cantidad posible de la variabilidad total de los datos, PC2 la mayor cantidad de la variabilidad restante, y asi sucesivamente.

Por que se usa en este proyecto: hay muchas variables (hasta 32 quimicas, hasta 22 sensoriales por bloque) medidas sobre pocas muestras —el escenario tipico de *small data* de alta dimensionalidad. Revisar variable por variable no deja ver el patron conjunto. Con PC1 y PC2 casi siempre alcanza para explicar la mayor parte de la varianza (en el ejemplo de la cata social, PC1 solo ya explica 77.9%), lo que permite graficar en dos dimensiones algo que en realidad vive en un espacio de 20-30 dimensiones.

Como se calculo: con `prcomp(x, center = TRUE, scale. = TRUE)` en R —se centra (resta la media) y se escala (divide por la desviacion estandar) cada variable antes de calcular los componentes, para que ninguna domine el resultado solo por tener una escala numerica mayor (ppm versus porcentaje versus puntaje 0-5).

Requisito minimo aplicado: se exigen al menos 3 filas (muestras/unidades) y 2 variables con variabilidad real; si no se cumple, la hoja de resumen marca ese grupo como `no_calculado` con el motivo, en vez de forzar un resultado no confiable.

Biplot

Que es: un grafico que combina dos capas sobre los mismos ejes PC1/PC2 —los *scores* (puntos: donde cae cada muestra segun sus valores en los componentes) y los *loadings* o cargas (flechas: cuanto y en que direccion aporta cada variable original a esos componentes).

Como leerlo:

- Dos puntos (muestras) cercanos entre si → perfiles similares en el conjunto de variables analizado.
- Una flecha larga → esa variable tiene mucho peso en como se separan las muestras en ese plano.
- Dos flechas casi paralelas y apuntando al mismo lado → esas variables estan correlacionadas positivamente.
- Dos flechas apuntando en direcciones opuestas → correlacion negativa.
- Una muestra ubicada en la direccion de una flecha → esa muestra tiende a tener valores altos en esa variable.

Por que se usa: es la forma mas directa de responder, en un solo grafico, "¿esta muestra se parece a esta otra, y por que variable especifica?" —sin el biplot habria que cruzar la tabla de scores con la de cargas manualmente.

ICC(1) — Coeficiente de Correlacion Intraclass (una via)

Que es: un estadistico que descompone la varianza total de un conjunto de puntuaciones en dos partes: la varianza *entre* los grupos que nos interesan (aqui, entre muestras distintas) y la varianza *dentro* de cada grupo (aqui, entre evaluadores que puntuaron la misma muestra). Si la varianza entre muestras es grande comparada con la varianza entre evaluadores, el ICC es alto: los evaluadores diferencian bien las muestras. Si el ruido entre evaluadores es comparable o mayor que la diferencia real entre muestras, el ICC es bajo o incluso negativo.

$$ICC(1) = (MSB - MSW) / (MSB + (n_0 - 1) \times MSW)$$

MSB = media cuadratica entre muestras · MSW = media cuadratica dentro de cada muestra (entre evaluadores) · n_0 = tamano de grupo promedio ajustado para el desbalance (formula de Fisher para disenos no balanceados).

Por que esta variante especifica: no todos los catadores evaluaron todas las muestras, y el numero de evaluadores por muestra varia (diseno no balanceado, no completamente cruzado). El ICC(1) de una via (modelo de

efectos aleatorios de un factor) es la formulacion clasica para este tipo de diseno, y se implemento directamente con la formula ANOVA en vez de usar un paquete externo (`psych` o `irr`) para no agregar dependencias nuevas al pipeline —el calculo es identico, solo que escrito a mano.

Como se interpreta en este proyecto (umbrales usados en la columna `interpretacion` de las hojas 21 y 22):

ICC(1)	Interpretacion
< 0	Sin concordancia: hay mas variacion entre evaluadores que diferencia real entre muestras.
0 – 0.2	Concordancia baja.
0.2 – 0.5	Concordancia moderada.
0.5 – 0.75	Concordancia buena.
≥ 0.75	Concordancia excelente.

Por que importa para la tesis: el ICC no es un adorno estadistico, es evidencia directa para matizar la advertencia metodologica ya establecida de que "las evaluaciones individuales son reales, pero el promedio agregado por muestra no siempre es igual de confiable en todos los bloques". El hallazgo de que `cata_alexandra_260603` tiene ICC bajo en varios targets es justamente el tipo de matiz que corresponde mencionar al discutir los resultados de ese bloque especifico.

7. Advertencias metodologicas generales del proyecto

Estas advertencias, ya establecidas para toda la tesis, tambien aplican a la lectura de estos tres analisis exploratorios:

1. La matriz de datos generados por IA (`E_ia_exploratoria`) no es una cata real, es un escenario sintetico exploratorio.
2. La matriz expandida por evaluador no contiene mas muestras quimicas independientes: son 52 unidades expandidas a 703 filas por evaluador.
3. El VIF global no es aplicable por la baja superposicion entre tecnicas analiticas (por eso el script 11b usa correlacion pareada simple, y el diagnostico formal usa VIF por bloque).
4. Los resultados son exploratorios por el contexto de *small data*: pocas muestras, alta dimensionalidad.
5. Las variables JU son senales fermentativas indirectas, no compuestos fenolicos causales.
6. Las variables GC-MS agregadas son apoyo contextual, no explicacion directa del atributo fenolico.
7. El enfasis debe estar en tendencias, estabilidad y coherencia quimica —no en prediccion industrial definitiva.

8. Indice de archivos generados

Tipo	Ruta
Excel quimico	Modelamiento/data/procesamiento/analisis_quimico.xlsx
Graficos quimicos	Modelamiento/outputs/exploratorio/quimico/
Excel sensorial	Modelamiento/data/procesamiento/analisis_sensorial.xlsx
Graficos sensoriales	Modelamiento/outputs/exploratorio/sensorial/
Excel cruzado quimico-sensorial	Modelamiento/data/procesamiento/analisis_cruzado_quimico_sensorial.xlsx
Graficos cruzados	Modelamiento/outputs/exploratorio/cruzado/
Scripts fuente	Modelamiento/scripts/R/exploratorio/10_analisis_quimico.R, 11_analisis_sensorial.R, 11b_eda_cruzado_quimico_sensorial.R