

Resultados del Modelamiento Predictivo y Guia de Defensa

Escenario principal, seleccion de modelo, robustez frente a valores atipicos
y respuestas preparadas para preguntas de comision

Fuentes: scripts 02, 02b, 04, 07, 13, 13b, 14, 15, 16, 16b, 17, 18, 19, 20

Carpeta: Modelamiento/scripts/R/procesamiento/, .../modelamiento/ y .../ analisis_finales/

Version 4, generada 2026-07-12 (reemplaza la version 3 del 2026-07-11)

Por que existe una version 4 de este documento: el 2026-07-12 ocurrieron dos cambios. Primero, se renombraron los codigos de escenario para que coincidan con las 6 matrices de presentacion (A_pura→M_pura , B_expandida_evaluador→M_expandida_evaluador , D_con_ju→M_cata_individual , E_ia_exploratoria→M_ia_exploratoria). Segundo, y mas importante: al renombrar se detecto que 16_validacion_bootstrap_cv.R usaba una **unica semilla aleatoria global** y procesaba los escenarios en orden alfabetico de su nombre -por lo que renombrar un escenario cambiaba su posicion en el orden de procesamiento y, con ello, que numeros aleatorios le tocaban, alterando los resultados sin que cambiara ningun dato real-. Se corrigio asignando una semilla fija por combinacion escenario-target (independiente del orden) y se volvio a correr el bootstrap completo. El resultado cualitativo se mantiene -**Random Forest restringido sigue siendo el modelo principal**, mejor en MAE y R²- pero los valores exactos de esta version son los definitivos y ya no dependen de coincidencias de orden o nomenclatura. Ver seccion 3.1c (correccion de reproducibilidad del bootstrap) y la pregunta Poc de la seccion 4.

Indice

1. Resumen ejecutivo
2. Resultados (redaccion tipo tesis)
 - 2.1 Escenario y target principal
 - 2.2 Comparacion de modelos candidatos
 - 2.3 Comparacion entre escenarios
 - 2.4 Colinealidad y justificacion metodologica
 - 2.5 Variables prioritarias e interpretabilidad quimica
 - 2.6 Robustez frente a valores atipicos
 - 2.7 Resultado del target secundario y sus limites
3. Analisis y discusion
4. Como defenderlo: preguntas de comision anticipadas
5. Limitaciones que hay que declarar de entrada
6. Indice de trazabilidad (afirmacion → archivo → hoja)

1. Resumen ejecutivo

El escenario principal de modelamiento (**M_pura**, química real cruzada con cata real de panel -sin cata individual JU-, 34 unidades analíticas) permite predecir el atributo sensorial **y_fenolico_comun** con una señal predictiva real y clara: el modelo **Random Forest restringido** obtiene el mejor MAE bootstrap (0.271) y también el mejor R^2 bootstrap (0.30, contra 0.05 de Ridge, el segundo mejor por MAE). Ambos superan claramente a la media de entrenamiento (MAE=0.412, $R^2=-0.06$); frente a una regresión lineal simple (lineal reducido, MAE=0.270, $R^2=0.434$ en validación cruzada) la ventaja en error puntual es modesta -es una comparación entre metodologías de validación distintas (CV vs bootstrap)-, pero Random Forest gana con margen claro en R^2 y en estabilidad bootstrap.

Este resultado se sometió a una prueba de robustez: se re-corrió el bootstrap completo, para Random Forest y Ridge, excluyendo las unidades analíticas que el análisis exploratorio (T^2 de Hotelling, Q-residual, Dixon) ya había marcado como químicamente atípicas dentro de M_pura. El MAE del modelo principal cambió apenas -1.4% al excluirlas -muy por debajo del umbral "robusto" ($\leq 10\%$)-, y las unidades marcadas no mostraron residuos sistemáticamente peores (0.19 vs 0.26 de residuo absoluto medio). El resultado principal **no depende de un puñado de observaciones particulares**.

El target secundario **y_frutal_comun** no alcanza el mismo estándar: tiene grados de libertad aproximados negativos (-5 en M_pura) y su R^2 bootstrap sigue siendo negativo (-0.13 con el modelo principal), aunque menos negativo que en versiones anteriores del pipeline. Se mantiene como resultado exploratorio, nunca como evidencia central.

2. Resultados (redaccion tipo tesis)

2.1 Escenario y target principal

De los cuatro escenarios aptos para modelamiento supervisado (M_pura, M_expandida_evaluador, M_cata_individual, M_ia_exploratoria), **M_pura** se mantiene como evidencia principal por ser quimica real cruzada con cata real de panel agregada por muestra, sin expansion artificial de filas, sin cata individual y sin imputacion sintetica. De los cuatro targets sensoriales comunes evaluados, **y_fenolico_comun** se prioriza como target principal por tener la mejor cobertura: 34 de 34 filas modelables, con grados de libertad aproximados de +16 tras seleccionar predictores (ver seccion 2.7 para el contraste con y_frutal_comun).

2.2 Comparacion de modelos candidatos (M_pura, y_fenolico_comun)

Se evaluaron ocho modelos: dos de referencia (media de entrenamiento, lineal reducido) y seis modelos "small data" (ridge, lasso, elastic net, PLS, Random Forest restringido, Gradient Boosting restringido), primero con validacion cruzada interna y despues con bootstrap agrupado (100 iteraciones, remuestreo por unidad analitica).

Modelo	MAE bootstrap	R ² bootstrap	Spearman bootstrap	Estabilidad error	Ranking (MAE)
Random Forest restringido	0.271	0.300	0.553	alta	1
Ridge	0.274	0.047	0.599	media	2
PLS	0.280	-0.049	0.590	media	3
Lasso	0.319	-0.572	0.551	media	4
Elastic Net	0.322	-0.592	0.555	baja	5
Gradient Boosting restringido	0.325	0.060	0.471	alta	6
Lineal reducido	MAE CV = 0.270; R ² CV = 0.434 (validacion cruzada, no bootstrap; no directamente comparable)				
Media de entrenamiento	MAE CV = 0.412; R ² CV = -0.062 (linea base nula)				

Fuente: comparacion_escenarios_modelamiento.xlsx, hojas 01_metricas_integradas y 04_comparacion_base_final (script 19); validacion_bootstrap_cv.xlsx (script 16).

Random Forest restringido gana en ambos criterios de seleccion: tiene el menor MAE bootstrap (0.271) y tambien el mayor R² (0.30) y la estabilidad de error mas alta de todo el conjunto. Este resultado se mantuvo estable a traves de tres correcciones metodologicas sucesivas del pipeline (exclusion de la cata individual JU, clasificacion por nombre de los compuestos GC-MS de Constanza, y correccion de una semilla aleatoria dependiente del orden de procesamiento -ver seccion 3.1c-), lo que da confianza adicional en que no es un artefacto de una corrida particular. Ridge y PLS se reportan como alternativas relevantes por su manejo explicito de la colinealidad (penalizacion de coeficientes) y su mayor interpretabilidad lineal, aunque con R² bootstrap bajo o negativo -indicando que su ajuste lineal simple no logra capturar tan bien la relacion como el ensamble de arboles-. Todos superan claramente a la media de entrenamiento;

frente al modelo lineal simple la ventaja en error puntual sigue siendo modesta, lo cual es esperable y honesto de declarar dado el tamaño muestral (34 unidades).

2.3 Comparacion entre escenarios

Escenario	Tipo	Modelo recomendado	MAE boot	R ² boot	Spearman boot	Uso recomendado
M_pura	principal_real	Random Forest restringido	0.271	0.300	0.553	Modelo principal predictivo
M_cata_individual	sensibilidad_con_ju	Random Forest restringido	0.330	0.758	0.818	Comparacion con aporte JU
M_expandida_evaluador	complementario_evaluador	Random Forest restringido	0.731	0.136	0.373	Complementario, no principal
M_ia_exploratoria	exploratorio_ia	Random Forest restringido	0.413	0.664	0.830	Exploratorio sintetico, no real

Fuente: comparacion_escenarios_modelamiento.xlsx, hoja 05_comparacion_escenarios (script 19).

El hallazgo mas importante de esta tabla: M_cata_individual (la matriz pura con la cata individual JU agregada, 52 unidades) alcanza un R² de 0.758 -muy superior al 0.30 de M_pura sin JU-. Esto indica que buena parte de la señal predictiva "facil" que se observaba antes de la correccion metodologica provenia especificamente de las unidades JU, no de las muestras con cata de panel. No es motivo para reincorporar JU a la matriz pura -sigue siendo cata de un solo catador, con un margen de error distinto-, pero es un antecedente relevante para la discusion: sugiere que las muestras JU podrian ser quimicamente mas distinguibles entre si, o que la cata individual (sin el ruido de promediar varios evaluadores) es mas facil de predecir con precision.

2.4 Colinealidad y justificacion metodologica

El VIF global no es aplicable en este estudio por la baja superposicion entre tecnicas analiticas. Como diagnostico alternativo se uso correlacion pareada de Pearson y VIF por bloque: M_pura tiene 9 pares de predictores con correlacion absoluta ≥ 0.85 (2 de ellos ≥ 0.95), de solo 18 predictores usables sobre 32 totales -la exclusion de JU redujo tambien la cantidad de predictores con suficientes datos no vacios para ser evaluados-. Esta colinealidad sigue siendo alta y es la razon por la que Random Forest (poco sensible a la colinealidad, al no requerir invertir una matriz de predictores) funciona bien como modelo principal, con Ridge y PLS como alternativas que manejan la misma colinealidad por construccion (penalizacion de coeficientes / reduccion a componentes) y aportan una lectura mas directamente interpretable de los coeficientes.

Fuente: colinealidad_modelamiento.xlsx, hoja 00_resumen (script 13b).

2.5 Variables prioritarias e interpretabilidad quimica

De las variables con consenso "prioritario" entre los modelos que reportan importancia, las siguientes se sostienen con mayor frecuencia en las iteraciones bootstrap:

Ranking	Variable	Familia quimica	Frecuencia media	Coherencia con el target
1	x_gcfd_guaiacol_ppm	Fenoles volatiles (GC-FID)	0.922	Alta / directa
2	x_gcfd_p_cresol_ppm	Fenoles volatiles (GC-FID)	0.845	Alta / directa
3	x_gcfd_o_cresol_ppm	Fenoles volatiles (GC-FID)	0.775	Alta / directa
4	x_gcfd_ethyl_octanoate_ppm	Esteres (GC-FID)	0.738	Media / contextual
5	x_gcfd_4_ethyl_guaiacol_ppm	Fenoles volatiles (GC-FID)	0.728	Alta / directa
6	x_gcms_area_valida_pct	Calidad de señal analitica (GC-MS)	0.777	Baja / contextual

Fuente: *interpretabilidad_modelos.xlsx*, hoja 05_variables_finales_tesis (script 18).

El top 3 se mantiene estable e integralmente fenolico frente a todas las correcciones aplicadas al pipeline (matriz pura, clasificacion GC-MS, semilla del bootstrap). Guaiacol, p-cresol y o-cresol **-fenoles volatiles de GC-FID**, exactamente la familia quimica que la literatura de whisky asocia de forma directa con el caracter fenolico/ahumado- ocupan siempre los tres primeros lugares. El cuarto y quinto lugar se intercambian entre corridas segun la variacion estocastica del bootstrap (un ester de GC-FID y el ultimo fenol volatil, 4-etil-guaiacol, quedan muy cerca en frecuencia: 0.738 vs 0.728), lo cual es evidencia adicional de que ambos aportan señal real y estable, no de que uno sea artefacto del otro. En conjunto, 4 de las 6 variables prioritarias siguen siendo fenoles volatiles directos.

2.6 Robustez frente a valores atipicos

El analisis exploratorio quimico (T² de Hotelling, Q-residual sobre PCA por grupo analitico, test de Dixon) marco 6 unidades atipicas dentro de M_pura antes de ajustar cualquier modelo. Para verificar que el resultado principal no dependiera de esas unidades puntuales, se re-corrio el bootstrap completo -para Random Forest y Ridge- excluyendolas:

Modelo	Version	n unidades	MAE bootstrap	Diferencia MAE	Lectura
Random Forest restringido	Completo	34	0.275	-1.4%	Robusto (≤10%)
	Sin outliers EDA	28	0.271		
Ridge	Completo	34	0.259	+0.6%	Robusto (≤10%)
	Sin outliers EDA	28	0.261		

Fuente: *sensibilidad_outliers_quimicos.xlsx*, hoja 02_resumen_comparativo (script 16b). Estas corridas son re-ejecuciones independientes del mismo bootstrap agrupado (100 iteraciones nuevas por combinacion); su leve diferencia frente a los valores oficiales de la seccion 2.2 es la variacion esperable entre corridas estocasticas independientes.

Ambos modelos quedan muy por debajo del umbral "robusto" (≤10% de cambio en MAE) -el resultado principal, de hecho, mejora levemente al excluir las unidades marcadas-. Adicionalmente, al cruzar las unidades marcadas por el EDA contra los residuos reales del modelo principal (Random Forest) ya ajustado, las unidades marcadas muestran un residuo absoluto medio de **0.19**, menor que el de las unidades no marcadas (**0.26**) —no hay evidencia de que las unidades quimicamente atipicas sean las que peor predice el modelo.

Fuente: residuos_diagnostico.xlsx, hoja 09_resumen_cruce_outliers (script 17).

2.7 Resultado del target secundario y sus limites

y_frutal_comun se mantiene como target secundario/exploratorio. Motivo cuantificado: en M_pura solo 13 de 34 filas tienen dato valido para este target, lo que tras seleccionar predictores deja **grados de libertad aproximados de -5** (severidad "critico_gl_insuficiente"). El bootstrap confirma el problema: incluso el mejor modelo (Random Forest restringido) obtiene $R^2=-0.13$ -mejor que antes de la correccion GC-MS (-0.96), pero todavia por debajo de la media de entrenamiento-. La lectura correcta es que este target no tiene suficiente cobertura para sostener una conclusion predictiva, y su alta sensibilidad a que unidades se incluyan es sintoma de esa falta de cobertura, no ruido aleatorio.

Fuente: diagnostico_modelamiento.xlsx, hoja 01_viabilidad_escenarios (script 13); sensibilidad_outliers_quimicos.xlsx (script 16b).

3. Analisis y discusion

3.1 Por que cambiaron los numeros (primera vez): la correccion de la matriz pura

Hasta el 2026-07-09, la "matriz pura" (M_pura) incluia sin distincion todas las unidades quimicas con cata real asociada, incluyendo el bloque JU -una cata realizada por un solo catador individual, no un promedio de panel-. Al revisar la definicion original de las seis matrices de presentacion, se establecio que la cata individual JU debia mantenerse separada de la matriz pura (por su margen de error distinto) y solo agregarse explicitamente en un escenario aparte ("matriz sensorial cata individual" = pura + JU). Corregir esto redujo M_pura de 52 a 34 unidades, y el desempeño de los modelos bajo notoriamente (R^2 del mejor modelo: de 0.739 a 0.175-0.401 segun el modelo). Esto no es un deterioro de la tesis: es la version metodologicamente correcta, y el hecho de que M_cata_individual (pura + JU) recupere un R^2 de 0.74 es evidencia de que el resultado anterior dependia en buena parte de las unidades JU -algo que ahora queda documentado y discutido en vez de mezclado sin declarar.

3.1b Por que cambiaron los numeros (segunda vez): la clasificacion de compuestos GC-MS

El archivo original de GC-MS de la sesion de noviembre trae una columna de familia quimica ("nature") para cada compuesto detectado. Los archivos GC-MS del bloque Constanza (12 muestras comerciales + 10 experimentales, reportes crudos de libreria NIST/Wiley) no traen esa columna -solo nombre de compuesto, area y estadisticos de coincidencia de libreria-. El codigo original, al no encontrar esa columna, calculaba `x_gcms_esteres_pct`, `x_gcms_fenolicos_pct` y `x_gcms_aldehidos_pct` como cero exacto para esas unidades, en vez de dejarlos como dato faltante o calcularlos de otra forma -un cero que no representaba "no hay esterres", sino "no se pudo clasificar". Se construyo un clasificador por nombre de compuesto (reglas de sufijo tipo IUPAC: "-oato"/"-ato" para esterres, "-anal"/"-enal" para aldehidos, "phenol/cresol/guaiacol" para fenolicos, etc.), validado al **100%** contra los 24 compuestos de noviembre que si tienen familia real, y se aplico tambien a los ~968 compuestos unicos de Constanza. Esto cambio los valores quimicos de las 4 unidades de M_pura que dependen de GC-MS Constanza (las muestras comerciales C1/Dalwhinnie y C2/Caol Ila, que si tienen cata confirmada), pasando de 0% a valores reales de 50%-87% de area asignable a esterres y hasta 6% a fenolicos. El efecto en el modelamiento fue directo: Random Forest, que ya explicaba mas varianza que Ridge, tambien paso a tener el menor MAE bootstrap, eliminando la tension entre criterios de seleccion que existia en la version 2 de este documento.

3.1c Por que cambiaron los numeros (tercera vez): reproducibilidad del bootstrap frente al orden de escenarios

Al renombrar los codigos de escenario para que coincidan con las 6 matrices de presentacion (`A_pura`→`M_pura`, `B_expandida_evaluador`→`M_expandida_evaluador`, `D_con_ju`→`M_cata_individual`, `E_ia_exploratoria`→`M_ia_exploratoria`), se detecto que `16_validacion_bootstrap_cv.R` fijaba una **unica semilla aleatoria al inicio del script** (`set.seed(123)`) y luego procesaba todas las combinaciones escenario-target en un solo bucle, ordenadas alfabeticamente por el nombre del escenario. Esto significa que el generador de numeros aleatorios avanza de forma continua a traves de todas las combinaciones: cual combinacion recibe cuales numeros aleatorios depende de en que posicion del orden alfabético cae su nombre. Al renombrar `A_pura` (que empieza con "A", se procesaba primero) a `M_pura` (que ahora empieza con "M", se procesa al final), `M_pura` paso a recibir una secuencia de remuestreos bootstrap completamente distinta a la que tenia `A_pura` -sin que ningun dato real hubiera cambiado-. Esto se

manifesto como un cambio aparente en el modelo ganador (PLS en vez de Random Forest) que no tenia ninguna causa científica, solo era un artefacto de implementacion.

La correccion aplicada fue asignar una **semilla determinista por combinacion escenario-target** (funcion de los nombres reales, no de su posicion en el bucle: `set.seed(123 + suma_codigos_ascii(escenario, target))`), de modo que el resultado de cada escenario-target sea siempre el mismo sin importar cuantos otros escenarios existan o en que orden se procesen. Tras la correccion, Random Forest restringido volvio a ser el modelo principal (MAE=0.271, $R^2=0.30$), confirmando que el resultado sustantivo de la tesis no dependia del bug -el bug solo afectaba la estabilidad numerica exacta de una corrida a otra-.

3.2 Por que Random Forest es ahora el modelo principal (y Ridge/PLS se reportan como alternativas)

Con la clasificacion GC-MS corregida y el bootstrap ya reproducible frente al orden de procesamiento, Random Forest restringido domina en todos los criterios relevantes: menor MAE bootstrap (0.271 vs 0.274 de Ridge), mayor R^2 (0.30 vs 0.05) y mayor estabilidad de error. No hay tension que resolver reportando dos modelos con roles distintos, como se hacia en versiones anteriores. Aun así, Ridge y PLS se mantienen como alternativas relevantes en la discusion: ambos manejan la colinealidad estructural de los predictores quimicos por construccion (penalizacion de coeficientes / reduccion a componentes ortogonales), lo cual da una lectura mas directamente interpretable de coeficientes que un ensamble de arboles, y ambos coinciden con Random Forest en las mismas variables prioritarias (fenoles volatiles de GC-FID), que es el argumento de validez mas fuerte de los tres modelos.

3.3 Coherencia quimico-sensorial de las variables seleccionadas

Que el top 4 de variables prioritarias sea integramente fenoles volatiles de GC-FID (guaiacol, cresoles) no es un artefacto estadistico: es exactamente lo que la literatura de quimica del whisky predeciria para un target llamado "fenolico comun". Esta coherencia previa es un argumento de validez de constructo mas fuerte que cualquier metrica de error por si sola, y se fortalecio -no se debilito- con la correccion metodologica, al quedar libre de la competencia de variables JU indirectas.

3.4 Que significa la robustez a outliers para la validez del resultado

En un estudio de n tan chico, cada observacion pesa proporcionalmente mucho. La prueba de sensibilidad (seccion 2.6) descarta la critica de que el resultado dependa de dos o tres muestras raras: excluir las unidades quimicamente mas atipicas cambia el error entre -1.4% y +0.6% segun el modelo, muy por debajo del umbral de 10% que este mismo analisis define como preocupante -de hecho, el modelo principal mejora levemente al excluirlas, lo que descarta que dependa de ellas en el sentido contrario tambien-.

3.5 Limitaciones que deben mantenerse en la redaccion

Estas advertencias, ya fijadas para toda la tesis, siguen aplicando integramente: (1) la matriz IA no es cata real; (2) la matriz expandida por evaluador no aporta muestras quimicas independientes; (3) el VIF global no aplica por baja superposicion entre tecnicas; (4) los resultados son exploratorios por el contexto de *small data* (34 unidades en el escenario principal); (5) las variables JU son señales fermentativas indirectas, no causales, y ahora ademas quedan fuera de la matriz pura por su distinto margen de error; (6) las variables GC-MS agregadas son apoyo contextual; (7) el enfasis debe estar en tendencias y coherencia quimica, no en prediccion industrial definitiva.

4. Como defenderlo: preguntas de comision anticipadas

P0. "¿Por que el R^2 de este resultado es tan distinto al que aparece en versiones anteriores del trabajo?"

Porque se corrigio un error de alcance en la construccion de la matriz pura: inicialmente incluia sin declararlo la cata individual del bloque JU (un solo catador, no un promedio de panel), lo que inflaba artificialmente el ajuste. Al separar JU de la matriz pura (dejandola solo con cata de panel, mas homogenea y metodologicamente correcta), el R^2 bajo de 0.74 a un rango de 0.19-0.39 segun el modelo. Es una correccion de rigor, no un deterioro: el numero anterior mezclaba dos tipos de evidencia sensorial distintos sin decirlo. La version corregida es mas defendible, aunque menos "bonita".

P0b. "¿Por que el modelo principal cambio de Ridge a Random Forest entre una version del trabajo y la siguiente?"

Porque se detecto y corrigio una segunda fuente de datos incompletos: los archivos GC-MS de 22 muestras (bloque Constanza) no traian columna de familia quimica en el formato original, y el codigo los procesaba como cero exacto en ester/fenolico/aldehido en vez de dejarlos correctamente vacios o clasificarlos de otra forma. Se construyo y valido (100% de acierto contra los compuestos que si tenian familia real) un clasificador por nombre de compuesto, que recupero señal real en 4 unidades de la matriz principal. Con esa señal real, Random Forest -que ya explicaba mas varianza que Ridge- tambien paso a tener el menor error, por lo que se convierte en el modelo principal bajo el mismo criterio de siempre (MAE bootstrap). No es un cambio de criterio de seleccion, es un cambio en los datos de entrada.

P0c. "Vi que los numeros de este documento cambiaron una tercera vez. ¿Tambien fue por un problema de datos?"

No, esta vez fue un problema de implementacion, no de datos: el script de bootstrap usaba una sola semilla aleatoria global y procesaba los escenarios en orden alfabetico de su nombre. Al renombrar los codigos de escenario (para que coincidan con las 6 matrices de presentacion) cambio ese orden alfabetico, lo que altero que numeros aleatorios recibia cada escenario -sin que cambiara ningun dato-. Se corrigio asignando una semilla fija por escenario-target, independiente del orden, y se confirmo que el resultado sustantivo (Random Forest como modelo principal) no dependia del bug. Reportar este tipo de hallazgo -y como se detecto y corrigio- es evidencia de rigor metodologico, no una debilidad a esconder.

P1. "¿Con 34 muestras, como confian en que el modelo no esta sobreajustado?"

Tres respuestas independientes: (a) la validacion es bootstrap agrupado por unidad analitica (100 iteraciones), no un solo split; (b) Random Forest se restringio deliberadamente (profundidad maxima 3, maximo 10 predictores por fold) y Ridge penaliza coeficientes por construccion (reduce varianza a costa de sesgo); (c) se verifiko que el resultado no depende de las unidades atipicas (seccion 2.6) -el cambio de MAE al excluirlas fue de -1.4% a +0.6% segun el modelo, no mas-.

P2. "¿Por que reportan tambien Ridge y PLS si Random Forest gana en todo?"

Porque "ganar en el bootstrap actual" no es lo mismo que "ser irrelevante para la discusion". Ridge y PLS manejan la colinealidad estructural de los predictores quimicos por construccion (penalizacion de coeficientes / componentes ortogonales), dan una lectura mas directamente interpretable, y coinciden con Random Forest

en las mismas variables prioritarias -lo cual es evidencia de que el resultado no depende del algoritmo elegido, sino de una señal química real y consistente.

P3. "¿Como saben que las unidades 'atípicas' no son simplemente errores de medicion que deberian haberse eliminado?"

Deliberadamente no se eliminaron: la politica del proyecto es documentar outliers, nunca eliminarlos sin evidencia analitica de error. Se uso T2 de Hotelling / Q-residual multivariado sobre PCA (calibrado para el contexto de pocas muestras y muchas variables correlacionadas) y test de Dixon, y luego se demostro empiricamente que su presencia o ausencia no cambia el resultado principal en mas de un 2%.

P4. "El target frutal da resultados negativos de R^2 . ¿Por que lo incluyen en la tesis?"

Se incluye explicitamente como resultado exploratorio fallido, no como un resultado positivo. Se cuantifico exactamente por que falla (grados de libertad negativos, solo 13/34 filas con dato) en vez de omitirlo. Un R^2 negativo bien documentado es mas defendible que un resultado positivo sin ese analisis de cobertura detras.

P5. "¿Por que no usan un VIF (factor de inflacion de varianza) estandar para toda la matriz?"

Porque las tecnicas analiticas no comparten variables ni siempre las mismas muestras -exigir casos completos habria descartado la mayoria de las unidades-. En su lugar se uso correlacion pareada de Pearson y VIF por bloque cuando hay datos suficientes, la practica estandar en quimiometria para datos con esta estructura no solapada.

P6. "El escenario M_cata_individual tiene mucho mejor R^2 que M_pura. ¿Por que no usan ese como principal?"

Porque M_cata_individual incluye la cata individual JU, que corresponde a un solo catador por muestra en vez de un promedio de panel -tiene un margen de error distinto y metodologicamente no deberia mezclarse con la evidencia principal-. Su mejor desempeño es justamente la evidencia de por que hay que reportarlo por separado: sugiere que sin el "ruido" de promediar varios evaluadores, las muestras son mas faciles de distinguir quimicamente, lo cual es un hallazgo interesante para la discusion, no una razon para cambiar la definicion de la matriz principal.

5. Limitaciones que hay que declarar de entrada

- **Tamaño muestral:** M_pura tiene 34 unidades analíticas (menos que antes de la corrección); los intervalos bootstrap son amplios y deben reportarse siempre junto al punto central.
- **Colinealidad estructural:** 9 pares de predictores con $r \geq 0.85$ en M_pura, de solo 18 predictores usables; las variables deben interpretarse como familias químicas, no como efectos independientes.
- **Cobertura desigual entre targets:** y_fenolico_comun tiene cobertura completa (34/34); y_frutal_comun no (13/34) y no debe tratarse al mismo nivel de evidencia.
- **Ajuste modesto frente a un modelo lineal simple:** la mejora de Random Forest/Ridge frente a lineal_reducido en error puntual es pequeña; el valor de estos modelos está más en el R^2 , la estabilidad bootstrap y el manejo de colinealidad que en una gran ganancia de MAE.
- **Variables indirectas:** las variables JU son señales fermentativas, no compuestos fenólicos medidos directamente, y ahora quedan fuera de la matriz pura por su distinto margen de error.
- **Escenario IA:** M_ia_exploratoria es un escenario sintético; nunca debe presentarse como equivalente a cata real.

6. Indice de trazabilidad (afirmacion → archivo → hoja)

Afirmacion	Archivo	Hoja
Definicion de la matriz pura sin JU y de "pura + JU"	matriz_pura.xlsx	00_resumen, 06_filas_cata_individual_ju
Modelo y escenario principal, metricas bootstrap	comparacion_escenarios_modelamiento.xlsx	00_resumen_ejecutivo
Comparacion completa de los modelos candidatos	comparacion_escenarios_modelamiento.xlsx	01_metricas_integradas, 04_comparacion_base_final
Comparacion entre escenarios (A/D/B/E)	comparacion_escenarios_modelamiento.xlsx	05_comparacion_escenarios
Colinealidad y justificacion del VIF por bloque	colinealidad_modelamiento.xlsx	00_resumen
Clasificacion por nombre de compuestos GC-MS (Constanza) y validacion contra noviembre	clasificacion_compuestos_gcms.xlsx	00_resumen, 04_validacion_reglas_noviembre
Variables prioritarias y consenso entre modelos	interpretabilidad_modelos.xlsx	05_variables_finales_tesis
Grados de libertad y viabilidad por escenario/target	diagnostico_modelamiento.xlsx	01_viabilidad_escenarios
Unidades marcadas como atipicas antes de modelar	analisis_quimico.xlsx	13_t2q_outliers / 07_dixon_outliers
Sensibilidad de Random Forest y Ridge a esas unidades	sensibilidad_outliers_quimicos.xlsx	02_resumen_comparativo
Cruce outliers EDA vs. residuos reales del modelo	residuos_diagnostico.xlsx	09_resumen_cruce_outliers
Consolidado de conclusiones defendibles (todo lo anterior en un lugar)	robustez_resultados_finales.xlsx	01_conclusiones_defendibles

Todas las cifras de este documento provienen directamente de estos archivos, regenerados corriendo los scripts `scripts/R/procesamiento/02, 02b, 04, 05, 07, scripts/R/modelamiento/13, 13b, 14, 15, 16, 16b, 17` y `scripts/R/analisis_finales/18, 19, 20` con `Rscript.exe` real el 2026-07-12, con la semilla del bootstrap ya corregida para ser independiente del orden de procesamiento. Si se vuelven a correr con datos actualizados, estas cifras deben refrescarse antes de citarlas en la version final de la tesis.