

Resultados finales y guía de defensa

Análisis químico-sensorial de la calidad del whisky chileno mediante técnicas de aprendizaje supervisado

Documento de apoyo interno para la defensa, complementario a la tesis. Reconstruido a partir de los datos vigentes del pipeline (post corrección de los bugs de ranking de variables, artefacto de Spearman y semilla de bootstrap). No reemplaza al documento de tesis.

1. Resumen ejecutivo

El escenario principal (`M_pura` , 34 unidades analíticas, 18 predictores usables, $n/p \approx 1.9$) muestra que **Random Forest restringido** es el modelo con mejor ajuste para `y_fenolico_comun` : MAE bootstrap 0.271 (rango P5–P95: 0.172–0.393), $R^2 = 0.300$, Spearman = 0.553, estabilidad de error alta. La señal se concentra en cuatro fenoles volátiles de GC–FID (4–etil–guaiacol, o–cresol, guaiacol, p–cresol), coherentes con la química conocida del carácter ahumado/fenólico. El resultado es robusto a valores atípicos químicos y a la imputación de GC–MS en el modelo principal (aunque no en Ridge). El target `y_frutal_comun` no alcanza evidencia suficiente (grados de libertad negativos) y el escenario de IA exploratoria no es comparable en desempeño al principal por un problema de circularidad explícito.

Indicador	Valor
Escenario / target principal	<code>M_pura</code> / <code>y_fenolico_comun</code>
Modelo principal	Random Forest restringido (300 árboles, profundidad máx. 3, máx. 10 predictores)
MAE bootstrap (media / P5 / P95)	0.271 / 0.172 / 0.393
R^2 bootstrap	0.300
Mejora sobre línea base (media de entrenamiento)	MAE 0.270 (modelo base) vs. 0.412 (media), $\approx 35\%$
Variables prioritarias (consenso 4 modelos)	4–etil–guaiacol, o–cresol, guaiacol, p–cresol (todas GC–FID)
Robustez a atípicos químicos	MAE cambia -1.4% (RF) / $+0.6\%$ (Ridge) al excluirlos
Robustez a imputación GC–MS	$+1.6\%$ (RF, robusto) / -11.9% (Ridge, sensibilidad moderada)

2. Síntesis de resultados por sección

2.1 Colinealidad

Colinealidad alta o muy alta en los cinco escenarios evaluados. En `M_pura` : 9 pares con $|r| \geq 0.85$ (2 de ellos ≥ 0.95), concentrados entre las variables de GC–MS (comparten cálculo por construcción) y entre fenólicos de GC–FID. Justifica priorizar modelos regularizados/de proyección sobre regresión lineal sin penalización.

2.2 Variables predictoras

Ranking	Variable	Frecuencia	Puntaje	Prioridad
1	4-etil-guaiacol (GC-FID)	0.73	0.86	prioritaria
2	o-cresol (GC-FID)	0.78	0.71	prioritaria
3	guaiacol (GC-FID)	0.92	0.68	prioritaria
4	p-cresol (GC-FID)	0.85	0.62	prioritaria
5-14	área válida, aldehídos, ethyl octanoate, isoamyl acetate, furfural, fenólicos y ésteres de GC-MS, ésteres de GC-FID	—	0.28–0.43	apoyo interpretativo

Fuente: `interpretabilidad_modelos.xlsx`, hoja `05_variables_finales_tesis` (regenerada 2026-07-28).

2.3 Desempeño de los modelos (M_pura, y_fenolico_comun)

Modelo	MAE	R ²	Spearman	Estabilidad
Random Forest restringido	0.271	0.300	0.553	alta
Ridge	0.274	0.046	0.599	media
PLS	0.280	−0.049	0.590	media
Lasso	0.319	−0.572	0.551	media
Elastic Net	0.322	−0.592	0.555	baja
Gradient Boosting restringido	0.325	0.060	0.471	alta

2.4 Comparación entre escenarios

Escenario	MAE	R ²	Lectura
M_pura	0.271	0.300	principal
M_cata_individual	0.330	0.758	R ² alto es artefacto de un solo catador, no mejor química
M_expandida_evaluador	0.731	0.136	peor desempeño, no aporta señal independiente
M_ia_exploratoria	0.413	0.664	no comparable, ver sección 3 (circularidad)

2.5 Residuos y sensibilidad

- Unidades marcadas atípicas en el EDA (n=6): residuo absoluto medio 0.187, frente a 0.261 en las no marcadas (n=28). No predicen peor.
- `y_frutal_comun` en `M_pura`: 13 filas modelables vs. 18 predictores, grados de libertad ≈ -5 (crítico). No se reporta como resultado central.
- ICC(1) en el bloque de cata individual de Alexandra: 0.02–0.27 (concordancia baja entre evaluadores), techo realista de desempeño para cualquier modelo sobre ese bloque.

3. Preguntas anticipadas de comisión

P: Si el MAE de Random Forest, Ridge y PLS es casi igual (0.271 vs. 0.274 vs. 0.280), ¿por qué declarar a Random Forest como modelo principal?

R: Esa diferencia de MAE (0.003–0.009) es pequeña frente a la desviación estándar del propio bootstrap (0.072 en RF, 0.11 en Ridge/PLS), así que no es, por sí sola, un criterio válido para elegir. La elección se basa en R^2 (0.300 vs. 0.046 vs. –0.049) y en la estabilidad de error (alta vs. media), donde la diferencia sí es clara. Ridge y PLS se mantienen como modelos de referencia para interpretación por su manejo explícito de la colinealidad.

P: Con $n/p \approx 1.9$, muy por debajo de la regla de 10 observaciones por variable, ¿cómo se justifica confiar en el resultado?

R: No se trata como un resultado definitivo, sino como evidencia preliminar de un escenario explícitamente caracterizado como *small data* (Peduzzi et al., 1996; Kokol et al., 2022). Por eso el diseño completo compensa esa limitación: modelos regularizados o restringidos en complejidad, selección de predictores solo dentro de cada partición de entrenamiento (sin fuga de información), y validación por bootstrap agrupado por unidad analítica en vez de una sola partición. El objetivo declarado es identificar señal defendible, no construir un modelo predictivo listo para producción.

P: ¿Por qué el carácter fenólico se modela bien y el frutal no?

R: `y_frutal_comun` tiene mucha menor cobertura de cata real dentro de `M_pura` (13 de 34 filas modelables), lo que deja grados de libertad negativos frente a los 18 predictores usables (sección de viabilidad estadística). No es que la química frutal sea irrelevante, es que no hay suficientes datos pareados química–sensorial para estimar ese modelo con confianza. Se reporta explícitamente como target secundario y exploratorio, nunca como evidencia predictiva.

P: Al agregar la cata individual JU (`M_cata_individual`), el R^2 sube de 0.30 a 0.76. ¿Por qué no usar esa matriz como principal si predice mucho mejor?

R: Porque esa mejora no refleja mejor química, sino que un solo catador es sistemáticamente más fácil de predecir que el promedio de un panel (sin el ruido de agregar varias personas). Es, de hecho, la justificación metodológica de por qué `M_pura` excluye esa fuente del escenario principal y la reserva como análisis de sensibilidad.

P: El escenario de IA exploratoria tiene $R^2=0.664$, más alto que el principal (0.300). ¿Significa que la IA predice mejor la calidad sensorial que el panel humano?

R: No, y es importante ser explícito en este punto. En ese escenario el propio target sensorial fue generado por el consenso de los mismos tres modelos de lenguaje (Gemini, Claude, GPT) que el modelo predictivo después intenta recuperar a partir de la química. La tarea no es predecir percepción humana real (con su ruido y desacuerdo entre catadores), sino recuperar la regla interna que los LLM usaron para pasar de química a puntaje. Ese R^2 alto refleja consistencia interna del proceso sintético, no validez predictiva. Además, ese escenario solo tiene 5 predictores usables con colinealidad extrema ($|r|$ máx. 0.964), y ningún bloque de GC–MS aportó evidencia (0/18 unidades estimables).

P: ¿Qué validez tiene entonces el escenario de IA, si no sirve como evidencia predictiva?

R: Su valor es exploratorio y limitado: demuestra que el consenso entre LLM puede aplicarse de forma internamente consistente cuando la evidencia química de entrada es interpretable (42 de 63 unidades químicas recibieron estimación, las 21 restantes se dejaron explícitamente sin estimar en vez de forzar un valor arbitrario). Se plantea como línea de trabajo futuro, no como resultado de esta tesis, y su validación independiente (con cata real reservada, nunca usada como ancla del consenso) queda pendiente.

P: GC–MS cubre solo el 23.5 % de las unidades de `M_pura` (8 de 34). ¿Cómo se maneja eso y qué tan confiable es?

R: Cada predictor con dato faltante se imputa por la mediana calculada únicamente con el pliegue de entrenamiento de esa iteración de validación, aplicada igual a entrenamiento y prueba, sin fuga de información. Dado que GC–MS depende mayoritariamente de esa imputación, se corrió un análisis de sensibilidad específico comparando el modelo con y sin esas 5 variables: Random Forest (el modelo principal) cambia menos de un 2 %, por lo que la conclusión central no depende de datos imputados. Ridge sí muestra sensibilidad moderada (11.9 %), por lo que las variables GC–MS se mantienen solo como apoyo interpretativo, nunca prioritarias.

P: El clasificador de compuestos GC–MS por nombre se validó con solo 24 compuestos y se aplicó a 968. ¿No es un conjunto de validación muy chico para confiar en el resto?

R: Sí, y se declara explícitamente como limitación. El 100 % de acierto en 24 casos no garantiza el mismo desempeño en los 968 restantes, aunque las reglas usadas son de nomenclatura química general (sufijos IUPAC), no ajustadas a esos 24 casos específicos. Por eso las variables de GC–MS derivadas de esta clasificación se tratan con más cautela que las de GC–FID en toda interpretación de resultados.

P: ¿Por qué bootstrap agrupado por unidad analítica y no una validación cruzada k–fold estándar?

R: Porque varias filas pueden corresponder a la misma muestra química base (réplicas analíticas, o distintos evaluadores en `M_expandida_evaluador`). Una partición aleatoria simple podría dejar réplicas de la misma muestra repartidas entre entrenamiento y prueba, inflando artificialmente el desempeño (fuga de información). Agrupar por `unidad_analitica_id` asegura que todas las filas de una misma muestra queden siempre juntas en un mismo lado de la partición, en cada una de las 100 iteraciones.

P: La reproducibilidad del bootstrap, ¿está garantizada?

R: Sí. Se corrigió un bug donde la semilla aleatoria dependa del orden en que se recorrían los escenarios dentro del script (dos corridas con distinto orden podían dar métricas ligeramente distintas). La corrección fija una semilla determinística por combinación escenario–target, derivada del nombre y no de la posición en el loop. Se verificó empíricamente corriendo el pipeline completo dos veces: las métricas resultantes son idénticas bit a bit.

P: El título y el objetivo hablan de "calidad" del whisky en general. ¿Por qué la conclusión solo habla de carácter fenólico?

R: Los datos disponibles no permiten construir un índice único de calidad global comparable entre los distintos paneles de cata (cada uno mide descriptores globales distintos y no estandarizados entre sí, como armonía, tomabilidad o integración del ahumado). Por eso "calidad sensorial" se operacionalizó a través de cuatro atributos específicos y medibles (fenólico, frutal, ahumado, medicinal), y de esos cuatro solo el fenólico contó con evidencia suficiente para una conclusión predictiva defendible. Esta distinción se declara explícitamente en el documento para no sobrestimar el alcance real de los hallazgos.

P: ¿Qué tan generalizable es este resultado a otras producciones de whisky chileno?

R: Limitadamente. Las muestras provienen de un conjunto acotado de fermentaciones experimentales (cepa B1, distintas condiciones) y muestras comerciales de referencia. El análisis es observacional, no experimental (no se manipuló fermentación, destilación ni maduración), por lo que la generalización a otras cepas, procesos o escalas de producción debe hacerse con cautela. Este carácter preliminar está declarado explícitamente en los alcances del proyecto.

P: Si un catador de un panel específico tiene ICC tan bajo (0.02–0.27), ¿eso no invalida usar sus datos?

R: No se descartan esas filas, pero sí se usan con esa limitación explícita. Un ICC bajo significa que los propios evaluadores de ese panel no concuerdan mucho entre sí al puntuar las mismas muestras, lo que impone un techo realista de desempeño: ningún modelo puede explicar más varianza sensorial de la que los evaluadores explican entre ellos. Es una limitación del dato de entrada, no del modelo, y se documenta como tal en vez de ignorarse.

4. Estado de verificación del pipeline (referencia interna)

Registro de la auditoría de consistencia realizada antes de cerrar la etapa de modelamiento. Todas las salidas listadas están regeneradas y son mutuamente consistentes a la fecha de este documento.

Verificación	Resultado
Bug de cálculo de residuos (script 17)	corregido
Artefacto de Spearman en baseline LOOCV (script 14)	corregido
Bug de normalización en ranking de variables (script 18)	corregido
Semilla de bootstrap dependiente del orden (script 16)	corregido y verificado (2 corridas idénticas)
Análisis de sensibilidad a outliers químicos (script 16b)	robusto
Análisis de sensibilidad a imputación GC–MS (script 16c, nuevo)	robusto en RF, moderado en Ridge
Cadena de dependencia scripts 19→20 desactualizada	corregido
Cifras del Capítulo 4 de la tesis vs. datos actuales	consistentes